



# Foundation of Machine Learning 5주차



정재현, 우지수/23.02.17



Computational Data Science LAB




# CONTENTS

1. Support Vector Machine
  2. Complementary Slackness: Margin and Support Vectors
  3. Subgradient
  4. Subgradient Descent
- 
- 

# 01 | Support Vector Machine

## Margin and hinge loss

- The Margin
  - ✓ 정의: 예측 score  $\hat{y}$  과 실제 class  $y \in \{-1, 1\}$ 에 대한 마진은  $y\hat{y}$  이다.
  - ✓  $yf(x)$ ,  $f(x)$  는 score function
  - ✓ 대부분 classification loss는 마진에만 의존
- Hinge Loss
  - ✓ SVM/Hinge loss:  $\ell_{Hinge} = \max\{1 - m, 0\} = (1 - m)_+$
  - ✓ 마진  $m = yf(x)$ ; “positive part”인  $(x)_+ = x1(x \geq 0)$
  - ✓  $m=1$ 일 때 미분이 불가
  - ✓ Margin error



# 01 | Support Vector Machine

## Support Vector Machine

- Hypothesis space

✓  $\mathcal{F} = \{f(x) = w^T x + b \mid w \in R^d, b \in R\}$

- SVM Optimization Problem

✓  $\min_{w \in R^d, b \in R} \frac{1}{2} \|w\|^2 + \frac{c}{n} \sum_{i=1}^n \max(0, 1 - y_i [w^T x_i + b])$

- ✓ Max가 있기에 미분이 불가

- *minimize*  $\frac{1}{2} \|w\|^2 + \frac{c}{n} \sum_{i=1}^n \xi_i$

- *subject to*  $\xi_i \geq \max(0, 1 - y_i [w^T x_i + b])$

- *minimize*  $\frac{1}{2} \|w\|^2 + \frac{c}{n} \sum_{i=1}^n \xi_i$

- *subject to*  $\xi_i \geq (1 - y_i [w^T x_i + b]) \text{ for } i = 1, \dots, n$

- $\xi_i \geq 0 \text{ for } i = 1, \dots, n$

# 01 | Support Vector Machine

## SVM Optimization Problem

- SVM Optimization Problem

- ✓ 최종적으로 다음과 같은 식 도출

- $minimize \quad \frac{1}{2} ||w||^2 + \frac{c}{n} \sum_{i=1}^n \xi_i$

- $subject \ to \quad (1 - y_i[w^T x_i + b]) - \xi_i \leq 0 \quad for \ i = 1, \dots, n$

- $-\xi_i \leq 0 \quad for \ i = 1, \dots, n$

- ✓ 위 식은 objective function이 이차식이고 제약식이 모두 affine이기에 quadratic program

- ✓ 미분이 가능

# 01 | Support Vector Machine

## SVM Dual Problem

Lagrange Multiplier	Constraint
$\lambda_i$	$-\xi_i \leq 0$
$\alpha_i$	$(1 - y_i [w^T x_i + b]) - \xi_i \leq 0$

- SVM Lagrange Multipliers

- $$L(w, b, \xi, \alpha, \lambda) = \frac{1}{2} \|w\|^2 + \frac{c}{n} \sum_{i=1}^n \xi_i + \sum_{i=1}^n \alpha_i (1 - y_i [w^T x_i + b] - \xi_i) + \sum_{i=1}^n \lambda_i (-\xi_i)$$

- $$= \frac{1}{2} w^T w + \sum_{i=1}^n \xi_i \left( \frac{c}{n} - \alpha_i - \lambda_i \right) + \sum_{i=1}^n \alpha_i (1 - y_i [w^T x_i + b])$$

- $$p^* = \inf_{w, \xi, b} \sup_{\alpha, \lambda \geq 0} L(w, b, \xi, \alpha, \lambda) \geq \sup_{\alpha, \lambda \geq 0} \inf_{w, \xi, b} L(w, b, \xi, \alpha, \lambda) = d^*$$

- ✓ Slater's condition (strong duality 만족)
- ✓ 따라서, SVM을 Quadratic Program으로 해결이 가능

# 01 | Support Vector Machine

## SVM Dual Function

- SVM Dual Function

- $g(\alpha, \lambda) = \inf_{w, b, \xi} L(w, b, \xi, \alpha, \lambda) = \inf_{w, b, \xi} [\frac{1}{2} w^T w + \sum_{i=1}^n \xi_i (\frac{c}{n} - \alpha_i - \lambda_i) + \sum_{i=1}^n \alpha_i (1 - y_i [w^T x_i + b])] ]$

- ✓ Strong duality를 만족( $p^* = d^*$ ) → KKT condition 만족
  - ✓ KKT condition – stationary condition

- SVM Dual Function: First Order Conditions

- $\partial_w L = 0 \Leftrightarrow w - \sum_{i=1}^n \alpha_i y_i x_i = 0 \Leftrightarrow w = \sum_{i=1}^n \alpha_i y_i x_i$
  - $\partial_b L = 0 \Leftrightarrow -\sum_{i=1}^n \alpha_i y_i = 0 \Leftrightarrow 0 = \sum_{i=1}^n \alpha_i y_i$
  - $\partial_{\xi_i} L = 0 \Leftrightarrow \frac{c}{n} - \alpha_i - \lambda_i = 0 \Leftrightarrow \frac{c}{n} = \alpha_i + \lambda_i$

# 01 | Support Vector Machine

## SVM Dual Function

- SVM Dual Function

- ✓ First order condition에 의해서 라그랑지안 primal 문제가 Dual 문제로 바뀜
- ✓  $\alpha_i$ 에 관한 문제로 단순해짐(primal solution에서의  $w$ 를 구할 때,  $w = \sum_{i=1}^n \alpha_i y_i x_i$ 이기에)

- $\sup_{\alpha} \quad \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j$

- s. t.  $\sum_{i=1}^n \alpha_i y_i = 0$

- $\alpha_i \in \left[0, \frac{c}{n}\right], \quad i = 1, \dots, n$




# 02 | Complementary Slackness: Margin and Support Vectors

## Insight From Complementary Slackness: Margin and Support Vectors

- The Margin

✓  $f^*(x) = x^T w^* + b^*$ 이 존재한다고 가정할 때 마진  $yf^*(x)$ 는 다음과 같음



- Support Vectors and The Margin

- ✓ “Slack Variable”이라고 부르는  $\xi_i^* = \max(0, 1 - y_i f^*(x_i))$ 는  $(x_i, y_i)$ 에서의 hinge loss
- ✓  $\xi_i^* = 0$ 이라고 가정하면 그 때의  $y_i f^*(x_i) \geq 1$
- ✓ 분류가 올바르게 된  $y_i f^*(x_i) \geq 1$ 의 hinge loss 0

## 02 | Complementary Slackness: Margin and Support Vectors

### Complementary Slackness

- Complementary Slackness Conditions

- ✓ First order condition에서의  $\nabla_{\xi_i} L = 0$ 은  $\lambda_i^* = \frac{c}{n} - \alpha_i^*$ 를 도출
- ✓ Strong duality(KKT condition)에 의해서, complementary slackness를 가짐
  - $\alpha_i^*(1 - y_i f^*(x_i) - \xi_i^*) = 0$
  - $\lambda_i^* \xi_i^* = \left(\frac{c}{n} - \alpha_i^*\right) \xi_i^* = 0$

Lagrange Multiplier	Constraint
$\lambda_i$	$-\xi_i \leq 0$
$\alpha_i$	$(1 - y_i f(x_i)) - \xi_i \leq 0$

- Consequences of Complementary Slackness Conditions

- ✓ 만약  $y_i f^*(x_i) > 1$ 이면 그 때의 margin loss는  $\xi_i^* = 0$ 이되고 위의 식에 대입해본다면  $\alpha_i^* = 0$
- ✓ 만약  $y_i f^*(x_i) < 1$ 이면 그 때의 margin loss는  $\xi_i^* > 0$ 이되고 위의 식에 대입해본다면  $\alpha_i^* = \frac{c}{n}$
- ✓ 만약  $\alpha_i^* = 0$ 이면 그 때의 margin loss는  $\xi_i^* = 0$ 이되고 이 말인 즉슨 loss가 없다는 것을 의미해 최종적으로  $y_i f^*(x_i) \geq 1$
- ✓ 만약  $\alpha_i^* \in \left(0, \frac{c}{n}\right)$ 이면 그 때의 margin loss는  $\xi_i^* = 0$ 이되고  $1 - y_i f^*(x_i) = 0$ .

## 02 | Complementary Slackness: Margin and Support Vectors

### Consequences of Complementary Slackness Conditions

- $\alpha_i^* = 0 \Rightarrow y_i f^*(x_i) \geq 1$
- $\alpha_i^* \in \left(0, \frac{c}{n}\right) \Rightarrow y_i f^*(x_i) = 1$
- $\alpha_i^* = \frac{c}{n} \Rightarrow y_i f^*(x_i) \leq 1$
  
- $y_i f^*(x_i) < 1 \Rightarrow \alpha_i^* = \frac{c}{n}$
- $y_i f^*(x_i) = 1 \Rightarrow \alpha_i^* \in \left[0, \frac{c}{n}\right]$
- $y_i f^*(x_i) > 1 \Rightarrow \alpha_i^* = 0$

## 02 | Complementary Slackness: Margin and Support Vectors

### Support Vector

- Support Vector

- ✓ 만약  $\alpha^*$ 가 dual problem의 해라고 하면, primal의 해는 다음과 같음

- ✓  $w^* = \sum_{i=1}^n \alpha_i^* y_i x_i$  , with  $\alpha_i^* \in \left[0, \frac{c}{n}\right]$

- The Bias Term: b

- ✓ SVM primal에서 complementary slackness condition

- $\alpha_i^* (1 - y_i f^*(x_i) - \xi_i^*) = 0$  (1)

- $\lambda_i^* \xi_i^* = \left(\frac{c}{n} - \alpha_i^*\right) \xi_i^* = 0$  (2)

- ✓  $\alpha_i^* \in \left(0, \frac{c}{n}\right)$ 와 같은  $i$ 가 있다고 가정

- ✓ (2)에 의해서  $\xi_i^* = 0$ 을 만족

- ✓ (1)에 의해서 다음식을 만족

- $y_i [x_i^T w^* + b^*] = 1$

- $\Leftrightarrow [x_i^T w^* + b^*] = y_i$  (use  $y_i \in \{-1, 1\}$ )

- $\Leftrightarrow b^* = y_i - x_i^T w^*$

## 02 | Complementary Slackness: Margin and Support Vectors

### Support Vector

- Support Vector

- ✓ 만약  $\alpha^*$ 가 dual problem의 해라고 하면, primal의 해는 다음과 같음

- ✓  $w^* = \sum_{i=1}^n \alpha_i^* y_i x_i$  , with  $\alpha_i^* \in \left[0, \frac{c}{n}\right]$

- The Bias Term: b

- ✓ SVM primal에서 complementary slackness condition

- $\alpha_i^* (1 - y_i f^*(x_i) - \xi_i^*) = 0$  (1)

- $\lambda_i^* \xi_i^* = \left(\frac{c}{n} - \alpha_i^*\right) \xi_i^* = 0$  (2)

- ✓  $\alpha_i^* \in \left(0, \frac{c}{n}\right)$ 와 같은  $i$ 가 있다고 가정

- ✓ (2)에 의해서  $\xi_i^* = 0$ 을 만족

- ✓ (1)에 의해서 다음식을 만족




- $y_i [x_i^T w^* + b^*] = 1$

- $\Leftrightarrow [x_i^T w^* + b^*] = y_i$  (use  $y_i \in \{-1, 1\}$ )

- $\Leftrightarrow b^* = y_i - x_i^T w^*$

# 03 | Subgradient REVIEW

- Support Vector
  - ✓ SVM의 목적은 마진을 최대화하는 것
  - ✓ SVM에서는 비용 함수가 다른 대부분의 머신 러닝 알고리즘들과 달리 매끄럽지 않은 형태(미분불가)
  - ✓ 경사하강법을 이용한 알고리즘이 아닌 다른 형태의 알고리즘
- Convex Sets
  - ✓ 어떤 집합이 주어져 있다고 할 때, 이 집합의 원소인 두 점을 잇는 선분이 이 집합에 포함 될 때 우리는 이 집합을 convex set이라 함
  - ✓ 두 점을 잇는 선분이 그래프 위에 있다면 convex하다고 하고  $-f$ 가 convex하다면  $f$ 는 concave하다고 함



# 03 | Subgradient

## Convex Optimization Problem: Standard Form

- Convex Optimization Problem: Standard Form

- *minimize*  $f_0(x)$

- *subject to*  $f_i(x) \leq 0, \quad i = 1, \dots, m$

- ✓ 이 때,  $f_0, \dots, f_m$ 은 모두 convex 함수

- Level Sets and Sublevel Sets

- ✓  $f: \mathbb{R}^d \rightarrow \mathbb{R}$  인 함수


- ✓  $f(x) = c$ 에 대해서  $x \in \mathbb{R}^d$ 에 모든 점들의 집합을 value  $c$ 에 대한 level set 혹은 contour line이라 함

- ✓  $f(x) \leq c$ 에 대해서  $x \in \mathbb{R}^d$ 에 모든 점들의 집합을 value  $c$ 에 대한 sublevel set이라 함


- ✓  $f: \mathbb{R}^d \rightarrow \mathbb{R}$  함수가 convex하다면 그 때의 sublevel set도 convex하다고 함

# 03 | Subgradient

## Level Sets and Sublevel Sets : convex



- Level Sets and Sublevel Sets
  - ✓ 이러한 convex function이 있다고 하자, 이때 floor는 domain으로서 2차원이고 그래프는 3차원
  - ✓ 중간에 평면으로 자른 지점이 level set이고 그 아랫부분이 sublevel set




- Level Sets and Sublevel Sets(contour plot)
  - ✓ 그리고 이걸 단면으로 봤을 때 중간에 있는 부분이 sublevel set이라고 할 수 있음




# 03 | Subgradient

## Level Sets and Sublevel Sets : non-convex



- Level Sets and Sublevel Sets
  - ✓ 3차원 그래프에서 non-convex함을 볼 수 있음





- Level Sets and Sublevel Sets(contour plot)
  - ✓ contour plot으로 봤을 때 sublevel set에서 중간점을 이어보면 non-convex함을 알 수 있음

# 03 | Subgradient

## Level Sets and Sublevel Sets

- Level Sets and Sublevel Sets

- ✓ Convex set의 특징으로는 convex set들의 교집합 또한 convex set이라는 성질을 가진다는 점
- ✓ 또 다른 특징으로는 그냥 level set이나 superlevel set( $f(x) > -1$ 인 부분)은 일반적으로 convex set이 아닐 수도 있다는 특징이 있음
- ✓ 결과적으로  $C$ 를 convex set이라고 했을 때 우리는 Convex Optimization Problem을 다음과 같이 쓸 수 있음
  - $\text{minimize } f_0(x)$
  - $\text{subject to } x \in C$
- ✓ 이때  $f$ 는 convex 함수이고  $C$ 는 convex set




# 03 | Subgradient

## First-Order Approximation

- First-Order Approximation(1차 근사)


- ✓  $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 가 미분 가능하다고 가정
- ✓  $y$ 를 추정하기 위해 1차 선형근사를 시키는 것을 알 수 있음
- ✓  $f(y) \approx f(x) + \nabla f(x)^T(y - x)$
- ✓ 만약 함수  $f$ 가 미분 가능하고, convex function 이라면 이것을 global underestimator이라 함
- ✓  $f(y) \geq f(x) + \nabla f(x)^T(y - x)$
- ✓  $\nabla f(x) = 0$ 이라면 그 때  $x$ 는  $f$ 의 global minimizer



# 03 | Subgradient

## Subgradient

- Subgradients
  - ✓  $f(z) \geq f(x) + g^T(z - x)$
  - ✓ 이 때  $g$ 를 subgradient라고 함
  - ✓ 이 때 빨간선들은 앞서 살펴봤던 global underestimator이고 그 안에  $g$ 가 subgradient
- Subdifferential
  - ✓ 만약  $x$ 에서 subgradient가 적어도 하나라도 존재한다면  $f$ 는  $x$ 에서의 subdifferentiable
  - ✓  $x$ 에서의 모든 subgradient의 집합은  $\partial f(x)$ 인 subdifferential이라고 부름
  - ✓ 만약  $f$ 가 convex하고 미분 가능하다면  $\rightarrow \partial f(x) = \{\nabla f(x)\}$
  - ✓ 만약  $\partial f(x) = \emptyset \rightarrow f$ 는 convex하지 않다



# 03 | Subgradient

## Global Optimality Condition



- Global Optimality Condition
  - ✓ vector  $g \in \mathbb{R}^d$ 는 모든  $z$ 에 대해  $x$ 에서  $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 의 subgradient
  - ✓  $f(z) \geq f(x) + g^T(z - x)$
  - ✓ 만약  $0 \in \partial f(x)$ 이면 그때의  $x$ 는  $f$ 의 global minimizer

# 03 | Subgradient

## Subdifferential of Absolute Value

- Subdifferential of Absolute Value


- ✓  $f(x) = |x|$
- ✓  $\{(x, g) | x \in \mathbb{R}, g \in \partial f(x)\}$



# 03 | Subgradient

$$f(x_1, x_2) = |x_1| + 2|x_2|$$


- Subgradients of  $f(x_1, x_2) = |x_1| + 2|x_2|$ 
  - ✓  $f(x_1, x_2) = |x_1| + 2|x_2|$ 에서  $(3, 0)$ 지점의 subdifferential
  - ✓  $|x_1|$ 의 subgradient는  $1$  ( $x_1 = 3$ )
  - ✓  $|x_2|$ 의 subgradient는  $[-2, 2]$  ( $x_2 = 0$ )
  - ✓  $h(x_1, x_2) = f(3, 0) + g^T(x_1 - 3, x_2 - 0)$
  - ✓ 이때,  $h$ 는 초평면이자  $f(x_1, x_2)$ 의 global underestimate
  - ✓  $g = (g_1, g_2)$
  - ✓  $g_1 = 1, \quad g_2 = [-2, 2]$



# 03 | Subgradient

$$f(x_1, x_2) = |x_1| + 2|x_2|$$

- Underestimating Hyperplane to  $f(x_1, x_2) = |x_1| + 2|x_2|$ 
  - ✓  $f(x_1, x_2) = |x_1| + 2|x_2|$ 에서  $(3, 0)$ 지점의 subdifferential
  - ✓  $|x_1|$ 의 subgradient는  $1$  ( $x_1 = 3$ )
  - ✓  $|x_2|$ 의 subgradient는  $[-2, 2]$  ( $x_2 = 0$ )
  - ✓  $h(x_1, x_2) = f(3, 0) + g^T(x_1 - 3, x_2 - 0)$
  - ✓ 이때,  $h$ 는 초평면이자  $f(x_1, x_2)$ 의 global underestimate
  - ✓  $g = (g_1, g_2)$
  - ✓  $g_1 = 1, \quad g_2 = [-2, 2]$






# 03 | Subgradient

## Subdifferential on Contour Plot

- Subdifferential on Contour Plot




# 03 | Subgradient

## Contour Line and Gradient

- Contour Line and Gradient

- ✓  $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 에서 함수의 그래프는  $\mathbb{R}^{d+1}$ 차원에서 존재
- ✓  $f$ 의 gradient나 subgradient는  $\mathbb{R}^d$ 차원에 존재
- ✓ 또한 등고선, level set 그리고 sublevel set 모두  $\mathbb{R}^d$ 에 존재
- ✓  $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 이 연속적으로 미분이 가능하고  $\nabla f(x_0) \neq 0$
- ✓ 그 때  $\nabla f(x_0)$ 은 level set  $S$ 에 대해서 수직이라고 할 때
- ✓ Level sets:  $S = \{x \in \mathbb{R}^d | f(x) = f(x_0)\}$



# 03 | Subgradient


## Contour Line and Subgradients

- Contour Line and Subgradients

- ✓  $f: \mathbb{R}^d \rightarrow \mathbb{R}$ , 점  $x_0$ 에서 subgradient  $g$ 가 존재
- ✓  $g$ 에 직교하는 초평면  $H$  level set  $S = \{x \in \mathbb{R}^d | f(x) = f(x_0)\}$ 를 support  
( $S$ 에서 모든 점들이  $H$ 의 한쪽에 위치한다는 뜻)

- Proof:


- ✓ 임의의  $y$ 에서  $f(y) \geq f(x_0) + g^T(y - x_0)$
- ✓ 만약  $y$ 가  $g$ 가 양수인 방향에 위치한다면,  $y - x_0$ 는  $g$ 와 평행하지 않으며 두 vector의 내적은 0보다 큼
- ✓ 그렇다면  $f(y)$ 는  $f(x_0)$ 의 값보다 커짐, 즉  $y$ 는  $S$ 에 포함되지 않음
- ✓ 따라서 모든  $S$ 의 원소들은  $H$ 위나  $H$ 의  $-g$  방향에 존재



# 03 | Subgradient

Subgradient of  $f(x_1, x_2) = |x_1| + 2|x_2|$

- Subgradient of  $f(x_1, x_2) = |x_1| + 2|x_2|$ 
  - ✓ 증명에 의해  $g$ 가 가리키는 방향에 위치한 점들은 함수  $f$ 보다 큰 값을 가짐
  - ✓ 즉, 이 점들은 함수  $f$ 를 더 크게 만드는 방향
  - ✓ 반면  $g$ 의 반대 방향은 함수  $f$ 보다 작을수도 있고 같을 수도 있음
  - ✓ 이러한 이유로 항상  $-g$ 가 감소하는 방향이 아닐 수 있음



# 04 | Subgradient Descent

## Subgradient Descent

- Subgradient Descent
  - ✓  $f$ 가 convex하고  $x_0$ 가 최적화 시작점이라 가정
  - ✓ 음수의 subgradient 방향에서의 step:  $x = x_0 - tg$ ,  $t > 0$  and  $g \in \partial f(x_0)$
- Subgradient Gets Us Closer To Minimizer
  - ✓  $z$ 가 임의의 점에서  $f(z) < f(x_0)$ 을 만족
  - ✓ 그렇다면 충분히 작은  $t > 0$ 에 대해서  $\|x - z\|_2 < \|x_0 - z\|_2$  또한 만족
  - ✓  $z = x^* \in \operatorname{argmin}_x f(x)$ 로 적용한다면 음수의 subgradient 방향에서의 step은 최소화 더 가깝게 만들어줌

# 04 | Subgradient Descent

## Subgradient Gets Us Closer To Minimizer

- Subgradient Gets Us Closer To Minimizer(Proof)

- ✓  $\|x - z\|_2^2 = \|x_0 - tg - z\|_2^2$

- ✓  $= \|x_0 - z\|_2^2 - 2tg^T(x_0 - z) + t^2 \|g\|_2^2$

- ✓  $\leq \|x_0 - z\|_2^2 - 2t[f(x_0) - f(z)] + t^2 \|g\|_2^2$

- $-2t[f(x_0) - f(z)] + t^2 \|g\|_2^2$

- ✓ Convex quadratic 문제이다.

- ✓  $t = 0$ 이고  $t = 2(f(x_0) - f(z))/\|g\|_2^2 > 0$ 일 때 0을 갖게 됨

- ✓ 그러므로, 이는 임의의  $t \in \left(0, \frac{2(f(x_0) - f(z))}{\|g\|_2^2}\right)$ 에서 음수

# 04 | Subgradient Descent

## Convergence Theorem

- ✓  $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 가 convex하고,  $f$ 가  $G > 0$  제약조건을 가진 Lipschitz 연속일 때
- ✓  $|f(x) - f(y)| \leq G \|x - y\|$ , for all  $x, y$

- Fixed Step Size

- ✓ 고정된 step size  $t$ 에서,  $\lim_{k \rightarrow \infty} f(x_{best}^k) \leq f(x^*) + G \frac{t^2}{2}$

- Decreasing Step Sizes

- ✓ 로빈스-몬로 조건과 관련된 step size의 경우,  $\lim_{k \rightarrow \infty} f(x_{best}^k) \leq f(x^*)$

# Q&A

---

감사합니다.