



Foundation of Machine Learning 6주차

정재현, 우지수 / 2023.02.24




Computational Data Science LAB

CONTENTS

1. What is SVM (Support Vector Machine) ?
2. Margin
3. SVM Primal and Dual
4. Hinge Loss and Subgradient

01 | What is SVM (Support Vector Machine) ?

Classification Algorithm



- ✓ 빨간색, 파란색 점을 분류할 수 있는 다양한 선형 분류 함수가 존재
- ✓ 그 중, 빨간색 점과 파란색 점의 집단 사이의 간격이 최대가 되도록 하는 최적의 선형 분류 함수를 탐색 = SVM

01 | What is SVM ?

Decision Boundary

- Hyper Plane (초평면)

= SVM에서 두 개의 클래스를 나누는 (Decision Boundary) 경계면

$$\underline{w}^T x + \overline{b} = 0$$

초평면의 법선 벡터
(기울기)

- ✓ 관측치가 초평면의 어디에 존재하느냐에 따라 관측치의 클래스 (y_i) 결정

01 | What is SVM ?

Decision Rule


- Hyper Plane (초평면)
- ✓ Decision Boundary (결정경계) 와 가장 가까운 관측치와의 거리를 최대화하는 것이 목적

제약조건 : $y_i(w^T x_i + b) \geq 1$

$y_i = 1$, i 번째 관측치는 양성 클래스

$y_i = -1$, i 번째 관측치는 음성 클래스

- ✓ SVM은 위의 제약 조건을 만족하며 두 초평면 사이의 거리를 최대로 만드는 기울기(w)와 b 를 구해야 함.



02 | Margin and Error

Maximize Margin

- Margin (마진)


= Decision Boundary (결정경계) 를 만드는 두 직선 사이의 거리

$$w = \begin{bmatrix} w_1 \\ w_2 \end{bmatrix}, x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$$\text{Margin} = \frac{|-(b+1)+(b-1)|}{\sqrt{w^T w}} = \frac{2}{\underline{\|w\|}}$$

초평면의 법선 벡터 (기울기)

w 의 크기



02 | Margin and Error

Maximize Margin

- Margin (마진)

$$\text{Maximize } \frac{2}{||w||}$$

$$\text{subject to } y_i(w^T x_i + b) \geq 1$$

역수

$$\text{Minimize } \frac{||w||^2}{2}$$

$$\text{subject to } y_i(w^T x_i + b) \geq 1$$

- ✓ 제약 조건이 있는 상황에서 최적화 문제를 해결해야 하므로 라그랑주 승수를 사용해야함.
- ✓ 이때, 마진의 역수를 취함으로써 라그랑주 승수 계산이 간단해지고 초평면의 기울기를 구하는 과정이 효율적이게 됨.

02 | Margin and Error

Minimize Error


- Error (ξ)

= 분리불가능한 선형 SVM 학습을 위해 사용

$$\text{Minimize } \frac{\|w\|^2}{2} + C \sum_{i=1}^n \xi_i$$

$$\text{subject to } y_i(w^T x_i + b) \geq 1 - \xi_i$$
$$\xi_i \geq 0, \sum \xi_i \leq \text{constant}$$

✓ ξ 가 1보다 크게 되면 관측치가 반대 클래스로 넘어가 있다는 의미



02 | Margin and Error

Minimize Error

- Error (ξ)

= 분리불가능한 선형 SVM 학습을 위해 사용

$$\text{Minimize } \frac{\|w\|^2}{2} + C \sum_{i=1}^n \xi_i$$

ξ 허용 정도를 정해주는 하이퍼파라미터

$$\text{subject to } y_i(w^T x_i + b) \geq 1 - \xi_i$$

$$\xi_i \geq 0, \sum \xi_i \leq \text{constant}$$

✓ C가 큰 경우 : Hard SVM (C가 커질수록 전체 식을 줄여야 하므로 그만큼 ξ 를 허용해주지 않는다는 의미)

ex) C가 무한대이면 모든 관측치가 마진 바깥에 위치 = Overfitting

✓ C가 작은 경우 : Soft SVM (ξ 를 어느정도 허용해준다는 의미)

03 | SVM Primal and Dual

To Minimize Cost Function

- Primal

$$\text{Minimize } \frac{\|w\|^2}{2} + C \sum_{i=1}^n \xi_i$$

$$\text{subject to } y_i(w^T x_i + b) \geq 1 - \xi_i$$
$$\xi_i \geq 0$$

- ✓ 마진을 최대화 시키면서 ($\|w\|^2$ 를 최소화 시키면서) ξ_i 를 최소화 하는 초평면을 구하는 것이 목적
- ✓ 이때, 우리가 찾아야하는 것은 초평면의 기울기 w 와 b → Dual

03 | SVM Primal and Dual

To Solve Hyper Plane

- Dual

$$L(w, b, \alpha) = \frac{\|w\|^2}{2} - C \sum_{i=1}^n \xi_i + \sum_{i=1}^n \alpha_i (y_i (w^T x_i + b) - 1 + \xi_i) + \sum_{i=1}^n \mu_i \xi_i$$

- ✓ 라그랑주 승수법을 통해 Primal 식에 존재했던 등식제약을 함수의 제약으로 옮겨서 제약이 없는 문제로 표현
- ✓ 위 식을 최소화하는 w, b, ξ_i 를 찾기 위해 라그랑주 승수 α_i, μ_i 도입



각각을 미분하여 0이 되는 해 찾기

1. w 에 대해 미분 : $\partial_w L = 0 \rightarrow w - \sum_{i=1}^n \alpha_i y_i x_i = 0 \rightarrow w = \sum_{i=1}^n \alpha_i y_i x_i$
2. b 에 대해 미분 : $\partial_b L = 0 \rightarrow - \sum_{i=1}^n \alpha_i y_i = 0 \rightarrow \sum_{i=1}^n \alpha_i y_i = 0$
3. ξ_i 에 대해 미분 : $\partial_{\xi_i} L = 0 \rightarrow C - \alpha_i - \mu_i = 0 \rightarrow \alpha_i + \mu_i = C$

03 | SVM Primal and Dual

To Solve Hyper Plane

- Dual

1. w 에 대해 미분 : $\partial_w L = 0 \rightarrow w - \sum_{i=1}^n \alpha_i y_i x_i = 0 \rightarrow w = \sum_{i=1}^n \alpha_i y_i x_i$
2. b 에 대해 미분 : $\partial_b L = 0 \rightarrow -\sum_{i=1}^n \alpha_i y_i = 0 \rightarrow \sum_{i=1}^n \alpha_i y_i = 0$
3. ξ_i 에 대해 미분 : $\partial_{\xi_i} L = 0 \rightarrow C - \alpha_i - \mu_i = 0 \rightarrow \alpha_i + \mu_i = C$



대입해줌으로써 α_i 로 모든 것을 표현 가능

$$\text{maximize} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j$$

03 | SVM Primal and Dual

To Solve Hyper Plane

- Dual

$$\text{maximize } \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j$$

- ✓ 이 식을 최대화하는 α_i 를 구한 후 w, b 식에 대입해주면 구할 수 있음.
- ✓ 이는 KKT condition을 만족한다고 가정

[KKT condition]

1. $\alpha_i [y_i (x_i^T w + b) - (1 - \xi_i)] = 0$
2. $\mu_i \xi_i = 0$
3. $y_i (x_j^T w + b) - (1 - \xi_i) \geq 0$

03 | SVM Primal and Dual

To Solve Hyper Plane

- Dual

[KKT condition]

1. $\alpha_i [y_i(x_i^T w + b) - (1 - \xi_i)] = 0$

2. $\mu_i \xi_i = 0$

3. $y_i(x_i^T w + b) - (1 - \xi_i) \geq 0$

✓ 3번째 조건을 만족한다고 하였을 때, 1번째 조건을 만족해야 라그랑주 문제를 풀 수 있음.

✓ 1번째 조건이 0이 되려면 α_i 가 0이 되거나 $y_i(x_i^T w + b) - (1 - \xi_i)$ 가 0이 되어야 한다는 의미임.

- $y_i(x_i^T w + b) - (1 - \xi_i) \neq 0$: 마진 바깥에 관측치가 존재하는 경우, α_i 가 0이 되어야함

- $\alpha_i \neq 0$: 관측치가 마진 위에 존재한다는 의미 = **support vector**

03 | SVM Primal and Dual

Support Vector

- Dual

$$\text{maximize } \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j$$


✓ α_i : 관측치 i 가 Support Vector인지에 대한 여부

$0 < \alpha_i < C$ 이면, Support Vector

$\alpha_i = 0$ 이면, 마진 밖에 위치

$\alpha_i = C$ 이면, 마진 내에 위치

✓ y_i : 기존 관측치 i 의 y 값



03 | SVM Primal and Dual

Support Vector and New Data

- Dual

$$\text{maximize } \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j$$

- ✓ α_i : 관측치 i 가 Support Vector인지에 대한 여부

- $0 < \alpha_i < C$ 이면, Support Vector


- $\alpha_i = 0$ 이면, 마진 밖에 위치

- $\alpha_i = C$ 이면, 마진 내에 위치

- ✓ y_i : 기존 관측치 i 의 y 값

- ✓ $x_i^T x_j$: support vector인 관측치 i 와 새로운 관측치 j 의 내적 (유사도, Kenel 함수)

→ 이를 통해 새로운 관측치 j 의 클래스를 분류해낼 수 있으며 비선형 SVM 해결 가능



03 | SVM Primal and Dual

Support Vector and Hyper Plane

- Dual

$$\text{maximize } \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j$$

$$w^* = \sum_{i=1}^n \alpha_i y_i$$
$$b^* = y_i - \sum_{i=1}^n \alpha_i y_i x_i^T x_j$$

→ Dual은 관측치 관점에서 초평면 (Hyper Plane)의 기울기 w 와 b 의 최적해를 구할 수 있음.

04 | Hinge Loss and Subgradient


SVM Objective Function

- SVM의 목적함수

$$\text{Minimize } \underbrace{\frac{\|w\|^2}{2}} + C \underbrace{\sum_{i=1}^n \max(0, 1 - y(x_i^T w + b))}_{\text{Hinge Loss (미분 불가능)}}$$

미분 가능

Hinge Loss (미분 불가능)



- ✓ SVM의 목적함수를 또다른 관점에서 보면 $\frac{\|w\|^2}{2}$ 와 Hinge Loss의 결합 형태
- ✓ 목적함수를 최소화 시키는 w 와 b 를 구해야 하지만 Hinge Loss는 미분 불가능


어떻게 최적화 하는 것일까 ?

04 | Hinge Loss and Subgradient

What is Hinge Loss ?

- Hinge Loss

- ✓ SVM에서 사용되는 손실함수
- ✓ 마진 (Margin) 을 최대화하려는 목표



$y_i(x_i^T w + b)$

$$L(y, (x_i^T w + b)) = \max(0, 1 - y(x_i^T w + b))$$


$$L(y, (x_i^T w + b)) = \begin{cases} \text{if } y_i(x_i^T w + b) \geq 1, & ; 0 \\ \text{if } y_i(x_i^T w + b) < 1, & ; 1 - y(x_i^T w + b) \end{cases}$$

$$L'(y, (x_i^T w + b)) = \begin{cases} \text{if } y_i(x_i^T w + b) > 1, & ; 0 \\ \text{if } y_i(x_i^T w + b) < 1, & ; -y \\ \text{if } y_i(x_i^T w + b) = 1, & ; ? \end{cases} \longrightarrow \text{Subgradient Descent}$$


04 | Hinge Loss and Subgradient

What is Subgradient ?

- Subgradient



미분




$$f'(x) = \begin{cases} \text{if } x > 0, & ; 1 \\ \text{if } x < 0, & ; -1 \\ \text{if } x = 0, & ; ? \end{cases}$$

✓ $x = 0$ 인 지점은 미분이 되지 않아 closed form이 도출되지 않음.

04 | Hinge Loss and Subgradient


What is Subgradient ?

- Subgradient



Subgradient of
 $f(x) = (g)$

미분




$$f'(x) = \begin{cases} \text{if } x > 0, & ; 1 \\ \text{if } x < 0, & ; -1 \\ \text{if } x = 0, & ; ? \end{cases}$$

- ✓ $x = 0$ 인 지점은 미분이 되지 않아 closed form이 도출되지 않음.
- ✓ 이를 해결하고자 위와 같은 직선을 만들었을 때 주 함수인 $f(x)$ 보다 아래에 위치하게 됨.
- ✓ 이때, $f(y) \geq f(x) + g^T(y - x)$ 식 성립

$$g = \begin{cases} \text{if } x > 0, & ; 1 \\ \text{if } x < 0, & ; -1 \\ \text{if } x = 0, & ; [-1, 1] \end{cases}$$

04 | Hinge Loss and Subgradient

Hinge Loss and Subgradient




Subgradient of $f(x) = g$

$$g = \begin{cases} \text{if } y_i(x_i^T w + b) > 1 & ; 0 \\ \text{if } y_i(x_i^T w + b) < 1 & ; -y \\ \text{if } y_i(x_i^T w + b) = 1, & ; [-y, 0] \end{cases}$$

04 | Hinge Loss and Subgradient

Solve Hinge Loss with Subgradient Descent



Subgradient of $f(x) = g$

$$g = \begin{cases} 0 & \text{if } y_i(x_i^T w + b) > 1 \\ \text{any value in } [0, 1] & \text{if } y_i(x_i^T w + b) = 1 \\ 1 & \text{if } y_i(x_i^T w + b) < 1 \end{cases}$$

$$\frac{\partial L}{\partial w} = \begin{cases} 0 & \text{if } y_i(x_i^T w + b) > 1 \\ -y_i x_i & \text{if } y_i(x_i^T w + b) = 1 \\ -y_i x_i & \text{if } y_i(x_i^T w + b) < 1 \end{cases}$$

$$\frac{\partial L}{\partial b} = \begin{cases} 0 & \text{if } y_i(x_i^T w + b) > 1 \\ -y_i & \text{if } y_i(x_i^T w + b) = 1 \\ -y_i & \text{if } y_i(x_i^T w + b) < 1 \end{cases}$$

Subgradient를 사용하여 gradient를 계산한 후,
 w 와 b 업데이트

$$w = w - t \left(C \frac{\partial L}{\partial w} + 2w \right)$$

$$b = b - t \left(C \frac{\partial L}{\partial b} \right)$$

04 | Hinge Loss and Subgradient

Solve Hinge Loss with Subgradient Descent

- t (Step Size)

= Subgradient Descent 알고리즘에서 각 업데이트 단계 시 현재 위치에서 이동할 거리를 결정하는 하이퍼파라미터

1. Fixed Step Size

2. Diminishing Step Size

= 초기에는 큰 t 를 사용함으로써 초기 수렴속도를 높이고 학습이 진행됨에 따라 점차 t 를 줄여나감으로써

최적점에 도달할 수 있게 함.

✓ 문제점 : Dual과 달리 Subgradient Descent로는 초평면의 w 과 b 를 찾는 방법론은 최적점이 근사치로 나옴. (non-convex이기 때문)

Q&A

감사합니다.