



Foundation of Machine Learning 9주차

정재현, 우지수 / 2023.03.16





Computational Data Science LAB



CONTENTS



1. Probability Distribution
 2. Likelihood
 3. Maximum Likelihood Estimation
 4. Generalized Linear Model (GLM)
- 
- 

00 | Extra Study

- f_β - score

$$F_\beta = (1 + \beta^2) * \frac{\text{precision} * \text{recall}}{(\beta^2 * \text{precision}) + \text{recall}}$$

- ✓ Precision과 Recall의 조화평균 값
- ✓ β 값이 1보다 크면 Recall의 비중이 커짐 (Ex. $\beta = 2$)

- Recall : 실제로 positive인 샘플 중에 모델이 positive라고 예측한 것
- Precision : positive라고 예측한 것 중에 실제로 positive 인 것

$$F_2 = (1 + 4) * \frac{\text{precision} * \text{recall}}{(4 * \text{precision}) + \text{recall}} \quad \rightarrow \quad \text{positive를 더 잘 찾아내는 모델} \left(\frac{TP}{TP+FP} \right)$$

- ✓ β 값이 1보다 작으면 Precision 비중이 커짐 (Ex. $\beta = 0.25$)

$$F_{0.5} = (1 + 0.25) * \frac{\text{precision} * \text{recall}}{(0.25 * \text{precision}) + \text{recall}} \quad \rightarrow \quad \text{negative를 더 잘 찾아내는 모델} \left(\frac{TP}{TP+FN} \right)$$

00 | Introduction

Background

- ✓ 관측치 (데이터) 를 잘 나타내는 모델을 찾아 예측을 하는 것이 목표




통계학적인 관점

- ✓ 모집단을 알기 위해 표본을 추출한 뒤, 이를 바탕으로 모집단의 분포를 잘 나타내는 모수 (파라미터) 를 추정
- ✓ 모집단에서 새로운 관측치 (데이터) 가 발생할 확률 예측 가능

00 | Introduction

Background

$$D = \{1, 4, 5, 6, 9\}$$



✓ 두 분포 중 위 표본 관측치는 어떤 분포로부터 추출되었을 확률이 더 높을까?

정규분포

✓ 우리는 관측치를 관찰함으로써 해당 관측치가 추출되었을 것으로 생각되는 모수 추정 가능

Ex) 평균

→ HOW ?

01 | Probability Distribution

Definition


- Probability Distribution (확률분포)
 - ✓ 확률변수가 취할 수 있는 값들과 그 값들이 나타날 확률의 분포
 - 어떤 확률적인 현상에서 발생하는 값들을 수학적으로 표현한 변수

01 | Probability Distribution

Type


1. Discrete Probability Distribution (이산확률분포)

- ✓ 확률변수가 취할 수 있는 값들이 이산적인 경우의 확률분포
- ✓ Ex) 베르누이 분포, 포아송 분포
- ✓ 확률질량함수 (Probability Mass Function, PMF) 를 사용하여 정의



2. Continuous Probability Distribution (연속확률분포)

- ✓ 확률변수가 취할 수 있는 값들이 연속적인 경우의 확률분포
- ✓ Ex) 정규분포, 지수분포, 감마분포
- ✓ 확률밀도함수 (Probability Density Function, PDF) 를 사용하여 정의



01 | Probability Distribution

Definition

- Probability Distribution (확률분포)

- ✓ 확률변수가 취할 수 있는 값들과 그 값들이 나타날 확률의 분포


어떤 확률적인 현상에서 발생하는 값들을 수학적으로 표현한 변수



- ✓ 관측치 (데이터) 에 대한 함수
- ✓ 우리가 가지고 있는 표본 관측치 (데이터) 를 바탕으로 모집단의 확률분포를 파악하고 예측 수행 가능
- ✓ 이때, 모집단의 분포를 잘 나타내는 모수를 추정하는 과정이 필요

02 | Likelihood Function Definition

- Likelihood (가능도)



02 | Likelihood Function

Definition

- Likelihood function (가능도 함수)

✓ $D = \{y_1, \dots, y_n\}$: 표본 (관측치)

✓ $p(y)$: 표본 (관측치) 의 확률분포

✓ θ : 모수 (파라미터)

무한 곱에 log함수를 취함으로써 summation로 만들어 미분 계산 용이

✓ $p(D; \hat{\theta}) = \prod_{i=1}^n p(y_i; \hat{\theta})$



$$\log p(D; \hat{\theta}) = \sum_{i=1}^n \log p(y_i; \theta)$$


각 표본 관측치가 해당 분포로부터 나왔을 가능도 (높이) 를 계산하여 곱함
= 관측치 추출은 독립적으로 연달아 일어나기 때문

02 | Likelihood Function

Definition


- Likelihood function (가능도 함수)
 - ✓ 모수 (파라미터) 에 대한 함수
 - ✓ 확률분포의 모수 (파라미터) 가 어떤 값일 때 가장 적합한지 결정 가능

Ex)




[포아송 분포]

$$p(k; \lambda) = \frac{\lambda^k e^{-\lambda}}{k!}$$



[베타 분포]

$$p(y; \alpha, \beta) = \frac{y^{\alpha-1} (1-y)^{\beta-1}}{B(\alpha, \beta)}$$



[감마 분포]

$$p(y; k, \theta) = \frac{1}{\gamma(k) \theta^k} y^{k-1} e^{-y/\theta}$$

03 | Maximum Likelihood Estimation

Definition

- Maximum Likelihood Estimation (최대우도 추정)

$$\begin{aligned}\hat{\theta} &= \underset{\theta \in \Theta}{\operatorname{argmax}} \log p(D, \hat{\theta}) \\ &= \underset{\theta \in \Theta}{\operatorname{argmax}} \sum_{i=1}^n \log p(y_i; \theta)\end{aligned}$$

최적화

미분



Closed form for the MLE

- ✓ 표본 관측치 (데이터) 를 가장 잘 설명하는 확률분포와 모수를 찾는 방법

03 | Maximum Likelihood Estimation

How to find ?

- Maximum Likelihood Estimation (최대우도 추정)

✓ Ex) 포아송 분포의 MLE 구하기

- $p(k; \lambda) = \frac{\lambda^k e^{-\lambda}}{k!}$

- $\log[p(k; \lambda)] = \log\left[\frac{\lambda^k e^{-\lambda}}{k!}\right] = k \log \lambda - \lambda - \log(k!)$

- $\log p(D, \lambda) = \sum_{i=1}^n [k_i \log \lambda - \lambda - \log(k_i!)]$

- $0 = \frac{\partial}{\partial \lambda} [\log p(D, \lambda)] = \sum_{i=1}^n \left[\frac{k_i}{\lambda} - 1 \right] \Rightarrow \lambda = \frac{1}{n} \sum_{i=1}^n k_i$  포아송 분포의 추정 모수 $\hat{\lambda}$ 는 관측치 k 의 평균

04 | Generalized Linear Model (GLM)

Compare to Linear Probabilistic Models

- GLM vs LPM

LPM

- ✓ 종속변수와 독립변수 사이의 관계를 설명하기 위해 선형함수 사용
- ✓ 종속변수가 연속형 일 경우에만 적용되며, 정규분포를 따른다고 가정

GLM

- ✓ 종속변수와 독립변수 사이의 관계를 설명하기 위해 Transfer Function을 사용
ex) 베르누이 분포일 경우 로지스틱 함수를 Transfer Function으로 사용
- ✓ 종속변수가 이산형, 연속형 일 수도 있음
ex) 베르누이 분포, 포아송 분포, 감마 분포 등

04 | Generalized Linear Model (GLM)

Bernoulli Regression

1. Bernoulli Regression (베르누이 회귀)

- ✓ Binary Classification (이진분류) 문제에서 사용
- ✓ 종속변수 Y 가 이진형 (0또는 1) 일 때, 독립변수 X 와의 관계를 모델링
- ✓ 각 x 에 대해 $y = \{0,1\}$ 값을 가질 확률을 예측 $\rightarrow p(y) = \text{베르누이 분포}$

$$\begin{array}{ccccc} x & \rightarrow & w^T x & \rightarrow & f(w^T x) = \theta = p(y = 1|x) \\ \in R^d & & \in R & & \in [0,1] \\ & & \text{Linear Predictor} & & \text{Transfer Function} \end{array}$$

04 | Generalized Linear Model (GLM)

Bernoulli Regression

1. Bernoulli Regression (베르누이 회귀)

$$\begin{aligned} \underline{p_w(D)} &= \prod_{i=1}^n p_w(y_i|x_i) = \prod_{i=1}^n \underline{[f(w^T x_i)]^{y_i} [1 - f(w^T x_i)]^{1-y_i}} \\ \text{베르누이 분포} & \qquad \qquad \qquad \text{로지스틱 함수} \\ \log p_w(D) &= \sum_{i=1}^n y_i \log f(w^T x_i) + (1 - y_i) \log [1 - f(w^T x_i)] \end{aligned}$$

- ✓ 로지스틱 함수 : 0과 1 사이의 값을 출력하며, 종속변수의 값이 1일 확률 도출
- ✓ 모델링을 위해 독립변수와 Transfer Function을 결정한 후, 최대 우도 추정 (MLE) 을 사용하여 모델을 학습
- ✓ MLE를 통해 관측된 데이터를 가장 잘 설명하는 파라미터 (w) 를 찾을 수 있음.

04 | Generalized Linear Model (GLM)

Bernoulli Regression

1. Bernoulli Regression (베르누이 회귀)

$$p_w(D) = \prod_{i=1}^n p_w(y_i|x_i) = \prod_{i=1}^n [f(w^T x_i)]^{y_i} [1 - f(w^T x_i)]^{1-y_i}$$

$$\log p_w(D) = \sum_{i=1}^n y_i \log f(w^T x_i) + (1 - y_i) \log [1 - f(w^T x_i)]$$

$$J(w) = -[\sum_{i=1}^n y_i \log f(w^T x_i) + (1 - y_i) \log [1 - f(w^T x_i)]]$$

Maimizing $\log p_w(D)$ 문제를
Minimizing log-likelihood 목적함수로 변경



미분

04 | Generalized Linear Model (GLM)

Possion Regression

2. Possion Regression (포아송 회귀)

- ✓ 종속변수 Y 가 양의 정수 일 때, 독립변수 X 와의 관계를 모델링
- ✓ 각 x 에 대해 $y = \{0, \infty\}$ 값을 가질 확률을 예측 $\rightarrow p(y) = \text{포아송 분포}$

$$\begin{array}{ccccc} x & \rightarrow & w^T x & \rightarrow & f(w^T x) = \lambda \\ \in R^d & & \in R & & \in [0, \infty] \\ & & \text{Linear Predictor} & & \text{Transfer Function} \end{array}$$

04 | Generalized Linear Model (GLM)

Possion Regression

2. Possion Regression (포아송 회귀)

$$\begin{aligned} \underline{p_w(D)} &= \prod_{i=1}^n p_w(y_i|x_i) = \prod_{i=1}^n \frac{e^{-f(w^T x_i)} \overbrace{f(w^T x_i)^{y_i}}^{\text{지수 함수}}}{y_i!} \\ \text{포아송 분포} \quad \log p_w(D) &= \sum_{i=1}^n [y_i \log w^T x_i - f(w^T x_i) - \log(y_i!)] \end{aligned}$$

- ✓ 지수 함수 : 0과 ∞ 사이의 값을 출력하며, 종속변수의 값이 양의 정수일 확률 도출
- ✓ 모델링을 위해 독립변수와 Transfer Function을 결정한 후, 최대 우도 추정 (MLE) 을 사용하여 모델을 학습
- ✓ MLE를 통해 관측된 데이터를 가장 잘 설명하는 파라미터 (w) 를 찾을 수 있음.

04 | Generalized Linear Model (GLM)

Conditional Gaussian Regression

3. Conditional Gaussian Regression (조건부 가우시안 회귀)

- ✓ 종속변수 Y 가 실수 (연속형) 일 때, 독립변수 X 와의 관계를 모델링
- ✓ 각 x 에 대해 $y = R$ 값을 가질 확률을 예측 $\rightarrow p(y) = \text{가우시안 분포}$

$$\begin{array}{ccccc} x & \rightarrow & w^T x & \rightarrow & f(w^T x) = \mu \\ \in R^d & & \in R & & \in R \\ & & \text{Linear Predictor} & & \text{Transfer Function} \end{array}$$

04 | Generalized Linear Model (GLM)

Conditional Gaussian Regression

3. Conditional Gaussian Regression (조건부 가우시안 회귀)

$$\begin{aligned} \underline{p_w(D)} &= \prod_{i=1}^n p_w(y_i|x_i) = \prod_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}} \exp\left(\frac{-(y_i - \overbrace{w^T x_i}^{\text{선형 함수}})^2}{2\sigma^2}\right) \\ \text{가우시안 분포} \quad \log p_w(D) &= \sum_{i=1}^n \log \left[\frac{1}{\sigma\sqrt{2\pi}} \right] + \sum_{i=1}^n \left(\frac{-(y_i - w^T x_i)^2}{2\sigma^2} \right) \end{aligned}$$

- ✓ 모델링을 위해 독립변수와 Transfer Function을 결정한 후, 최대 우도 추정 (MLE) 을 사용하여 모델을 학습
- ✓ MLE를 통해 관측된 데이터를 가장 잘 설명하는 파라미터 (w) 를 찾을 수 있음.

Q&A

감사합니다.